2026.03.24

Anthropic Engineering Blog

장시간 실행 앱 개발을 위한 하네스 설계

Harness Design for Long-Running Application Development

Prithvi Rajasekaran · Anthropic Labs

GAN-Inspired | Multi-Agent | Generator-Evaluator

CORE QUESTION

고품질 프론트엔드와 완전 자율 개발, 두 마리 토끼를 잡는 법

GAN에서 영감을 받은 Generator-Evaluator 멀티 에이전트 시스템으로 주관적 판단을 구체적이고 채점 가능한 기준으로 변환

01

단순 구현의 한계

컨텍스트 윈도우 열화와 자기평가 편향이 장시간 태스크에서 품질을 저하

02

Generator-Evaluator 분리

생성과 평가를 분리하여 객관적 품질 향상의 강력한 레버 확보

03

하네스의 진화

모델 발전에 따라 불필요한 스캐폴딩을 제거하고 새로운 조합 탐색

01

핵심 문제점

왜 단순한 구현은 실패하는가

WHY NAIVE FAILS

두 가지 치명적 문제

A

컨텍스트 윈도우 열화

Context Window Degradation

- ✓ 긴 작업에서 컨텍스트가 채워지면 모델 일관성 저하
- ✓ "컨텍스트 불안" — 한계에 가까워지면 조기 마무리 경향
- → **해결:** 압축보다 완전 리셋이 더 효과적

B

자기평가 편향

Self-Evaluation Bias

- ✓ 에이전트가 자기 결과물을 자신 있게 칭찬 (품질 무관)
- ✓ 디자인 같은 주관적 태스크에서 특히 치명적
- → **해결:** 생성 에이전트와 평가 에이전트를 분리

02

프론트엔드 디자인 품질 평가

주관적 품질을 채점 가능하게 만드는 방법

GRADING CRITERIA

4가지 디자인 평가 기준

01

디자인 품질 (Design Quality)

부분의 집합이 아닌 하나의 일관된 전체로 느껴지는가? 색상, 타이포그래피, 레이아웃, 이미지가 결합되어 고유한 분위기와 정체성을 만드는가?

02

독창성 (Originality)

템플릿 기본값이나 AI 패턴(보라색 그라데이션 + 흰 카드)이 아닌, 인간 디자이너가 인식할 수 있는 의도적 선택의 증거가 있는가?

03

완성도 (Craft)

타이포그래피 위계, 간격 일관성, 색상 조화, 대비율 등 기술적 실행 수준. 창의성이 아닌 역량 검증

04

기능성 (Functionality)

미적 요소와 독립적으로 사용자가 인터페이스를 이해하고, 주요 액션을 찾고, 직관적으로 완료할 수 있는가?

SYSTEM ARCHITECTURE

Generator-Evaluator 반복 시스템

Claude Agent SDK 기반 생성 → Playwright MCP 기반 평가 → 5~15회 반복

Generator
HTML/CSS/JS
프론트엔드 생성

→

Live Page
실제 브라우저
렌더링

→

Evaluator
네비게이션 + 스크린샷
기준별 채점

→

전략 결정
개선 vs
완전 피벗

5~15	4h	4	2
반복 횟수/생성	전체 실행 시간	평가 기준	전략 옵션

> *"평가 기준의 문구가 Generator를 예상치 못한 방향으로 이끌었다. 'museum quality' 같은 표현이 특정 시각적 수렴을 유도했다."*

CASE STUDY

네덜란드 미술관 웹사이트 — 10번째 반복의 돌파

반복 1~9회: 점진적 개선

1. 기본적 레이아웃 + 색상 체계 수립
5. 타이포그래피 위계와 간격 정리
9. **세련되었지만 전형적인 디자인** — 컨벤셔널한 갤러리 레이아웃

반복 10회: 완전한 재구상

- **CSS 원근법** 으로 렌더링된 3D 방
- **체커보드 바닥** 위의 공간적 경험
- 벽에 **자유롭게 배치된 작품**
- 갤러리가 아닌 **"공간적 경험"** 으로 탈바꿈

✓ 첫 번째 반복 출력도 기존 기준선을 이미 초과 — 프롬프팅 자체가 모델을 제네릭 디자인에서 이탈하도록 유도

03

풀스택 코딩으로 확장

3-에이전트 아키텍처와 스프린트 계약

THREE-AGENT ARCHITECTURE

3-에이전트 아키텍처

에이전트 간 통신은 파일 기반 — 명세 충실성 유지 + 구현 자유도 확보

P

Planner

입력: 1~4문장

단순 프롬프트를 종합 제품 명세서로 확장. 세부 구현이 아닌 **결과물과 기술 방향** 중심. AI 기능 통합 기회도 식별

G

Generator

스프린트 단위

React + Vite + FastAPI + SQLite/PostgreSQL 스택. 한 번에 하나의 기능 구현, 자체 평가 후 QA에 전달, git으로 버전 관리

E

Evaluator

Playwright MCP

실제 사용자처럼 앱과 상호작용. UI, API, DB 상태 테스트. 각 스프린트 전 **"스프린트 계약서"**로 완료 기준 협상

COMPARISON

Solo Run vs Full Harness

RetroForge: 2D 레트로 게임 메이커 — Opus 4.5 기준

항목	Solo Run	Full Harness
소요 시간	20분	6시간
비용	$9	$200
기능 범위	기본 에디터	16개 기능, 10 스프린트
결과 품질	낭비된 레이아웃, 경직된 워크플로우, 깨진 게임 메카닉	스프라이트 애니메이션, 사운드, AI 생성, 공유 기능
핵심 차이	문제 표시 없음, UI 가이드 없음	일관된 시각 아이덴티티, 작동하는 게임

✓Full Harness의 **Claude 통합**: 프롬프팅으로 게임 컴포넌트를 생성하여 워크플로우를 크게 가속

QA CHALLENGES

QA 프로세스의 도전과 한계

Evaluator의 초기 문제

1. 합법적 이슈를 식별하지만 **합리화** 하여 수용
2. **표면적 테스트** 만 수행, 엣지 케이스 미탐색
3. 기대 판단과의 차이를 기반으로 QA 프롬프트 반복 조정

조정 후에도 잔존하는 한계

- ⚠ 미세한 레이아웃 이슈
- ⚠ 비직관적으로 느껴지는 인터랙션
- ⚠ 중첩된 기능에 숨어있는 미발견 버그

> *"Evaluator는 상당한 튜닝이 필요했다. 기대 판단과의 차이를 기반으로 반복 업데이트해야 했다."*

04

하네스의 진화

Opus 4.6과 함께 불필요한 스캐폴딩 제거

KEY PRINCIPLE

Opus 4.6으로 단순화

> *"하네스의 모든 컴포넌트는 모델이 혼자 할 수 없다는 가정을 인코딩한다. 그 가정은 스트레스 테스트할 가치가 있다."*

변화	이전 (Opus 4.5)	이후 (Opus 4.6)
스프린트 분해	필수 — 일관성 유지 불가	불필요 — 장시간 일관된 작업
Evaluator 역할	항상 필수	복잡한 태스크에만 가치
계획 수립	세밀한 스캐폴딩 필요	자체 계획 + 디버깅 가능
판단 기준	Evaluator의 필요성 = 태스크 복잡도 ÷ 모델 능력	

Opus 4.6 개선 사항: **향상된 계획 수립**, 지속적 에이전틱 태스크 수행, 대규모 코드베이스 안정 운영, 코드 리뷰/디버깅 강화, 긴 컨텍스트 검색 향상

CASE STUDY

Browser DAW — $124.70으로 완성

"브라우저에서 Web Audio API를 활용한 완전한 기능의 DAW를 만들어라"

단계	시간	비용
Planner	4.7분	$0.46
Build 1	2h 07m	$71.08
QA 1	8.8분	$3.24
Build 2	1h 02m	$36.89
QA 2	6.8분	$3.09
Build 3	10.9분	$5.88
QA 3	9.6분	$4.06
합계	**~4시간**	**$124.70**

QA가 발견한 핵심 갭

- ⚠ 클립 드래그/이동 불가
- ⚠ 악기 UI 패널 미구현 (신디사이저 노브, 드럼 패드)
- ⚠ 이펙트 시각화가 수치 슬라이더만 사용
- ⚠ 오디오 녹음이 스텁 상태

최종 결과

프롬프팅만으로 간단한 곡 제작 가능 — 템포, 키 설정, 멜로디, 드럼 트랙, 믹서 조정, 리버브 추가

05

핵심 교훈

모델이 발전해도 하네스의 공간은 축소되지 않는다 — 이동한다

KEY TAKEAWAYS

3가지 핵심 레슨

01

실험 우선

실제 문제에 대상 모델로 실험하고, 트레이스(실행 기록) 기반으로 성능을 튜닝하라. 이론이 아닌 관찰에서 시작

02

분해와 전문화

복잡한 태스크를 분해하고 특화된 에이전트를 각 측면에 적용하라. 생성과 평가의 분리가 핵심 레버

03

새 모델 출시 시 재검토

비핵심 컴포넌트를 제거하고, 더 큰 능력을 가능케 하는 새로운 조각을 추가하라. 하네스는 살아있는 시스템

> *"흥미로운 하네스 조합의 공간은 모델이 발전해도 축소되지 않는다. 대신 이동한다. AI 엔지니어의 흥미로운 작업은 다음 새로운 조합을 계속 찾는 것이다."*

ANTHROPIC

하네스는 축소되지 않는다
이동한다

Harness Design for Long-Running Application Development
Prithvi Rajasekaran · Anthropic Labs · 2026.03.24